

# 中山大学计算机学院 人工智能 本科生实验报告

(2023 学年春季学期)

## 一、 实验题目

NLI(自然语言推理)

## 二、 实验内容

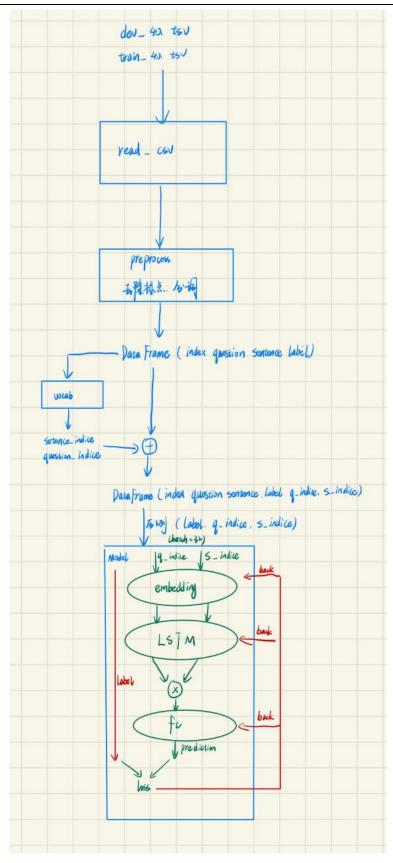
### 1. 算法原理

自然语言推理(NLI)是一种自然语言处理(NLP)任务,旨在让机器理解句子之间的逻辑关系。NLI 算法的核心目标是确定两个给定的句子——通常是一对前提和假设——之间的语义关系。

本代码模型首先将输入的文本序列进行预处理,之后构建一个词汇表,通过遍历训练集和测试集,将所有单词加入到 set 中,并将词汇表转换为词索引对应的字典。接着利用字典把词向量转换为索引向量,再经过一系列处理后送入神经网络(关于神经网络具体细节在下面关键代码部分给出),使用交叉熵损失函数和 Adam 优化器进行优化。

#### 2. 流程图







#### 3. 关键代码展示(带注释)

#### 数据预处理

使用 QUOTE NONE, 读取时忽略引号作为句子的分隔

```
# 下载 NLTK 的 punkt 模型
nltk.download('punkt')
# 读取数据集
def read tsv(file path):
   return pd.read_csv(file_path, sep='\t', header=None, names=['index',
'question', 'sentence', 'label'], quoting=csv.QUOTE_NONE)
train_df = read_tsv('QNLI/train_40.tsv')
dev_df = read_tsv('QNLI/dev_40.tsv')
# 数据预处理函数
def preprocess_text(text):
   text = text.lower() # 转为小写
   text = re.sub(f"[{string.punctuation}]", "", text) # 移除标点符号
   text = word_tokenize(text) # 分词
   return text
# 应用预处理函数
train df['question'] = train df['question'].apply(preprocess text)
train_df['sentence'] = train_df['sentence'].apply(preprocess_text)
dev_df['question'] = dev_df['question'].apply(preprocess_text)
dev_df['sentence'] = dev_df['sentence'].apply(preprocess_text)
```

#### 词向量转换索引向量

```
# 将句子转换为索引序列

def convert_to_indices(sentence, word2idx):
    return [word2idx[word] if word in word2idx else 0 for word in sentence]

train_df['question_indices'] = train_df['question'].apply(lambda x: convert_to_indices(x, word2idx))

train_df['sentence_indices'] = train_df['sentence'].apply(lambda x: convert_to_indices(x, word2idx))

dev_df['question_indices'] = dev_df['question'].apply(lambda x: convert_to_indices(x, word2idx))

dev_df['sentence_indices'] = dev_df['sentence'].apply(lambda x: convert_to_indices(x, word2idx))
```



```
# 将标签转换为数值
label2idx = {'entailment': 1, 'not_entailment': 0}
train_df['label'] = train_df['label'].map(label2idx)
dev df['label'] = dev df['label'].map(label2idx)
train df = train df.dropna(subset=['label'])
dev_df = dev_df.dropna(subset=['label'])
train_df['label'] = train_df['label'].astype(int)
dev_df['label'] = dev_df['label'].astype(int)
# 自定义数据集类
class NLIDataset(Dataset):
   def __init__(self, df):
       self.df = df
   def __len__(self):
       return len(self.df)
   def getitem (self, idx):
       question = torch.tensor(self.df.iloc[idx]['question_indices'])
       sentence = torch.tensor(self.df.iloc[idx]['sentence indices'])
       label = torch.tensor(self.df.iloc[idx]['label']).long()
       return question, sentence, label
#数据对齐(padding)
def collate fn(batch):
   questions, sentences, labels = zip(*batch)
    questions_padded = pad_sequence(questions, batch_first=True,
padding_value=0)
    sentences_padded = pad_sequence(sentences, batch_first=True,
padding value=0)
   labels = torch.stack(labels)
   return questions padded, sentences padded, labels
```

#### 神经网络定义

```
class NLIModel(nn.Module):
    def __init__(self, vocab_size, embed_size, hidden_size,
    output_size):
        super(NLIModel, self).__init__()
        self.embedding = nn.Embedding(vocab_size, embed_size,
    padding_idx=0)
        self.lstm = nn.LSTM(embed_size, hidden_size, batch_first=True,
    bidirectional=True)
```



```
self.fc = nn.Linear(hidden_size * 2, output_size)

def forward(self, question, sentence):
    question_embed = self.embedding(question)
    sentence_embed = self.embedding(sentence)

_, (question_hidden, _) = self.lstm(question_embed)
_, (sentence_hidden, _) = self.lstm(sentence_embed)

question_hidden = torch.cat((question_hidden[-2],
question_hidden[-1]), dim=1)
    sentence_hidden = torch.cat((sentence_hidden[-2],
sentence_hidden[-1]), dim=1)

combined = question_hidden * sentence_hidden
    output = self.fc(combined)

return output
```

超参数 vocab\_size = 67605(单词数量),embed\_size = 100,hidden\_size = 128,output\_size = 2(二分类),batch\_size = 32。

以 question 为例,我们首先将形状为[batch\_size, length]的 question 语句索引向量输入到嵌入层中,每个句子的单词被嵌入成一个高维向量,因此输出后形状变为 [batch\_size, length, embed\_size],接着输入到双向 LSTM 层,由于双向,所以形状为[2, batch\_size, hidden\_size],调用 torch.cat 函数将正向和反向序列拼接,得到形状为[batch\_size, hidden\_size \* 2]的张量,经过 combined 层进行 question 和 setence 的逐元素乘积,在经过全连接层,输出为[batch\_size, 2]的张量,用于二分类。

## 4. 创新点&优化(如果有)

- 1、神经网络中,选择双向 LSTM 层(长短期记忆网络),通过两个不同的隐藏层进行处理,一个正向序列,另一个反向序列,捕捉前后文信息。
- 2、数据对齐(padding),在创建 batch 时,由于每个样本的长度不同,使用 pad sequence 函数统一输入维度。

# 三、 实验结果及分析

|-------如有优化, 请重复 1, 2, 分析优化后的算法结果------------|

